

Laporan Akhir Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024C
Ketua	Siti Aisyah Febriyanti (24031554158)
Anggota 1	Arimbi Deby Setyoningrum (24031554186)
Anggota 2	Mutiara Nur Fadhilatun Nimah (24031554116)
URL Github	https://github.com/kicaw-mania

Informasi Umum Proyek

Judul	Klasifikasi Penyakit Daun Jagung Menggunakan Convolutional Neural Network dan Ensemble Classifier untuk Mendukung Ketahanan Pangan
Topik	Pangan
Pilihan Rumusan Masalah	1.2 Lambatnya Adopsi Teknologi dan Transformasi Digital dalam Ekosistem Pangan <i>lihat: https://risbang.kemdiktisaintek.go.id/rumusan-masalah.html</i>
Revisi?	Ya / Tidak

Pendahuluan

Latar belakang	Jagung merupakan salah satu komoditas pangan strategis yang berperan penting dalam mendukung ketahanan pangan nasional. Selain sebagai bahan pangan pokok di beberapa daerah, jagung juga dimanfaatkan sebagai bahan baku industri pakan ternak dan produk olahan pangan. Namun, produktivitas tanaman jagung sering mengalami penurunan akibat serangan penyakit daun seperti: <i>Common Rust</i>, <i>Gray Leaf Spot</i>, dan <i>Northern Leaf Blight</i> yang dapat menghambat pertumbuhan tanaman hingga menyebabkan gagal panen. Oleh karena itu, identifikasi penyakit daun jagung secara akurat menjadi langkah penting untuk menjaga produktivitas pertanian[1]. Identifikasi penyakit daun jagung masih banyak dilakukan secara manual melalui pengamatan visual oleh petani maupun tenaga ahli. Cara ini membutuhkan waktu, bergantung pada pengalaman pengamat serta rentan terhadap kesalahan identifikasi akibat kemiripan gejala antar penyakit[2]. Selain itu, variasi kondisi citra seperti pencahayaan, sudut pengambilan gambar, dan kompleksitas pola visual daun menjadi tantangan dalam proses klasifikasi. Perkembangan <i>machine learning</i>, khususnya <i>Convolutional Neural Network</i> (CNN), menjadi alternatif dan solusi klasifikasi citra yang efektif melalui kemampuan ekstraksi fitur visual secara otomatis. Penelitian Ashwini dan Sellam menunjukkan bahwa CNN mampu mengekstraksi fitur untuk mendukung klasifikasi penyakit daun jagung dengan akurasi yang tinggi[3]. Untuk meningkatkan performa klasifikasi, CNN dapat dikombinasikan dengan <i>ensemble classifier</i> seperti <i>Random Forest</i> dan <i>XGBoost</i> yang memiliki kemampuan generalisasi yang baik[4]. Penelitian ini relevan dengan rumusan masalah pangan yang dipaparkan oleh Direktorat Jenderal Riset dan Pengembangan terkait “Lambatnya Adopsi Teknologi dan Transformasi Digital dalam Ekosistem Pangan” karena
----------------	---


	memanfaatkan teknologi pembelajaran mesin sebagai implementasi <i>smart agriculture</i> [5]. Oleh karena itu, penelitian ini bertujuan mengembangkan model klasifikasi penyakit daun jagung menggunakan CNN sebagai <i>feature extractor</i> dan <i>Random Forest</i> dan <i>XGBoost</i> sebagai <i>classifier</i> untuk mendukung peningkatan produktivitas pertanian dan ketahanan pangan.
Rumusan masalah dan tujuan	Berdasarkan latar belakang yang telah dipaparkan, diperlukan penelitian yang mampu mengintegrasikan teknologi <i>machine learning</i> sebagai solusi klasifikasi otomatis penyakit daun jagung dalam mendukung transformasi digital sektor pertanian. Untuk menjawab permasalahan tersebut, maka dirumuskan beberapa pertanyaan penelitian sebagai berikut: 1. Bagaimana menerapkan CNN dan <i>ensemble classifier</i> sebagai solusi klasifikasi otomatis penyakit daun jagung dalam mendukung transformasi digital sektor pangan? 2. Bagaimana proses <i>preprocessing</i> dan ekstraksi fitur citra daun jagung menggunakan CNN untuk menghasilkan representasi fitur yang optimal? 3. Bagaimana implementasi <i>Random Forest</i> dan <i>XGBoost</i> dalam mengklasifikasikan penyakit daun jagung berdasarkan fitur hasil ekstraksi CNN? 4. Bagaimana performa kedua model berdasarkan metrik <i>accuracy</i>, <i>precision</i>, <i>recall</i>, dan <i>f1-score</i>? 5. Metode <i>classifier</i> manakah yang paling efektif untuk mendukung pengembangan sistem <i>smart farming</i> guna meningkatkan ketahanan pangan? Adapun tujuan dari penelitian ini adalah sebagai berikut: 1. Melakukan <i>preprocessing</i> dan ekstraksi fitur citra daun jagung menggunakan CNN untuk memperoleh representasi fitur visual penyakit daun jagung. 2. Mengimplementasikan <i>Random Forest</i> dan <i>XGBoost</i> sebagai <i>ensemble classifier</i> untuk melakukan klasifikasi jenis penyakit daun jagung berdasarkan fitur hasil ekstraksi CNN. 3. Melakukan evaluasi dan analisis performa model klasifikasi menggunakan metrik <i>accuracy</i>, <i>precision</i>, <i>recall</i>, dan <i>f1-score</i> guna mendukung klasifikasi penyakit tanaman pada sektor pangan.
Metodologi	
Ringkasan dataset	Dataset yang digunakan dalam penelitian ini adalah dataset Corn or Maize Leaf Disease Dataset yang diperoleh dari platform Kaggle. Dataset ini berisi kumpulan citra digital daun jagung yang digunakan untuk mendukung proses klasifikasi penyakit tanaman jagung berbasis citra digital menggunakan metode <i>machine learning</i> dan <i>deep learning</i>. Dataset terbagi ke dalam beberapa kategori penyakit, yaitu <i>Blight</i>, <i>Common Rust</i>, <i>Gray Leaf Spot</i>, serta daun sehat (<i>Healthy</i>). Distribusi awal menunjukkan adanya ketidakseimbangan pada 4 class dalam dataset yaitu <i>Common Rust</i> terdiri atas 1.044 citra, <i>Healthy</i> sebanyak

937 citra, kelas *Blight* sebanyak 911 citra, dan Gray Leaf Spot hanya memiliki 458 citra. Untuk mengatasi ketidakseimbangan kelas yang berpotensi memengaruhi performa model, dilakukan teknik undersampling dengan menyesuaikan jumlah citra pada setiap kelas menjadi 458 citra, sehingga total dataset berjumlah 1.832 citra. Dataset kemudian dibagi dengan rasio 80% data latih, 10% data validasi, dan 10% data uji untuk memastikan model dapat dilatih, divalidasi, dan diuji secara optimal.

Secara teknis, citra dalam dataset memiliki variasi resolusi yang cukup besar, dengan rata-rata lebar sebesar 307,53 piksel dan rata-rata tinggi sebesar 297,9 piksel, serta nilai standar deviasi yang relatif tinggi. Variasi ukuran ini berpotensi memengaruhi konsistensi proses pelatihan model. Oleh karena itu, dilakukan tahap resize untuk menyeragamkan seluruh citra menjadi berukuran 224×224 piksel sebelum proses pelatihan model dilakukan.

Alur jalannya penelitian, mulai dari pengumpulan data hingga pelatihan model disajikan dalam *flowchart* berikut:

Alur penelitian



Gambar 1. Diagram Alur Penelitian

1. **Data Asli:** Tahap ini adalah tahap pengumpulan dataset citra penyakit daun jagung yang diperoleh dari Kaggle. Dataset terdiri atas empat kelas, yaitu *Blight*, *Common Rust*, *Gray Leaf Spot*, dan *Heathy*. Dataset ini

	digunakan sebagai sumber data utama untuk proses klasifikasi penyakit daun jagung berbasis citra digital. 2. Standarisasi: Melakukan resize sehingga seluruh citra diubah ukurannya menjadi 224×224 piksel dan merubah citra 4 saluran menjadi 3 saluran. Hal ini dilakukan untuk menyeragamkan dimensi gambar. Proses ini dilakukan karena ukuran citra pada dataset sangat bervariasi sehingga perlu disesuaikan dengan kebutuhan input model CNN. Selain itu, resize membantu mengurangi kompleksitas komputasi selama proses pelatihan. 3. Split Dataset: Melakukan dengan membagi dataset menjadi data <i>training</i> (80%), <i>validation</i> (10%) dan <i>testing</i> (10%). Pembagian ini bertujuan untuk proses pelatihan, validasi, dan pengujian model secara objektif serta menghindari terjadinya <i>data leakage</i> selama penelitian. 4. Under Sampling: Dataset awal memiliki distribusi kelas yang tidak seimbang. Untuk menghindari bias model terhadap kelas mayoritas, dilakukan teknik <i>under sampling</i> dengan menyamakan jumlah data pada setiap kelas menjadi 458 citra. Proses ini menghasilkan distribusi data yang lebih seimbang sehingga model dapat mempelajari karakteristik setiap kelas secara lebih adil. 5. CLAHE (Contrast Limited Adaptive Histogram Equalization): CLAHE diterapkan untuk meningkatkan kualitas kontras citra. Metode ini bekerja dengan memperjelas detail lokal pada gambar sehingga pola penyakit, bercak, dan perubahan warna daun menjadi lebih terlihat. 6. Gaussian Blur: Setelah peningkatan kontras, citra diproses menggunakan <i>Gaussian Blur</i> dengan kernel 5×5 untuk mengurangi <i>noise</i> atau gangguan pada gambar. Proses ini membantu menghaluskan citra tanpa menghilangkan informasi penting yang diperlukan dalam proses ekstraksi fitur. 7. Normalization: Nilai piksel citra dinormalisasi dari rentang 0-255 menjadi 0-1. Normalisasi dilakukan agar proses pelatihan model menjadi lebih stabil, mempercepat konvergensi, dan mengurangi pengaruh perbedaan intensitas warna antar citra. 8. CNN (MobileNetV2): Citra hasil preprocessing kemudian dimasukkan ke model <i>Convolutional Neural Network</i> (CNN) dengan arsitektur <i>MobileNetV2</i>. Pada tahap ini model mengekstraksi berbagai fitur visual penting seperti tekstur, pola bercak, bentuk kerusakan daun, dan variasi warna yang berkaitan dengan penyakit tanaman jagung. 9. Random Forest: Melakukan klasifikasi dengan menggabungkan banyak <i>decision tree</i> sehingga menghasilkan prediksi yang lebih stabil dan mengurangi risiko <i>overfitting</i>. 10. XGBoost: Menggunakan pendekatan boosting untuk memperbaiki kesalahan prediksi secara bertahap sehingga mampu meningkatkan performa klasifikasi.
--	---

	11. Evaluasi model: Tahap terakhir adalah mengevaluasi performa model menggunakan data uji. Evaluasi dilakukan dengan metrik <i>Accuracy</i>, <i>Precision</i>, <i>Recall</i> dan <i>F-1 Score</i>. Hasil evaluasi digunakan untuk membandingkan performa <i>Random Forest</i> dan <i>XGBoost</i> dalam mengklasifikasikan penyakit daun jagung serta menentukan model yang paling optimal.
Proses <i>wrangling</i>	Proses <i>Wrangling</i> dilakukan untuk memahami, membersihkan, dan mempersiapkan dataset sebelum masuk ke tahap pemodelan. Tahapan yang dilakukan adalah sebagai berikut: 1. Resize (Handling Outlier) <i>Outlier</i> dimensi ditangani dengan menyeragamkan seluruh citra ke ukuran 224 x 224 piksel dengan 3 channel warna (RGB). Dimensi ini dipilih karena merupakan input shape standar yang optimal untuk arsitektur <i>MobileNetV2</i> yang digunakan sebagai <i>feature extraction</i>. <pre> 1 try: 2 img = Image.open(img_path).convert("RGB") 3 img = img.resize(target_size) 4 img.save(save_path) </pre> Gambar 2. Potongan code <i>resize</i> Beberapa citra dalam dataset memiliki format RGBA (4 channel), yaitu citra yang menyertakan channel Alpha (transparansi) di samping tiga channel warna red, green, dan blue. Channel Alpha ini tidak dibutuhkan dalam proses klasifikasi citra dan justru akan menyebabkan inkonsistensi dimensi input apabila tidak ditangani, karena model <i>MobileNetV2</i> hanya menerima input dengan 3 channel (RGB). Penanganan dilakukan dengan mengkonversi seluruh citra ke mode RGB dari library <i>Pillow</i> pada saat proses <i>resize</i> berlangsung. Konversi ini secara otomatis menghapus channel Alpha dan menyeragamkan seluruh citra menjadi 3 channel warna, sehingga tidak ada lagi inkonsistensi channel dalam dataset yang digunakan untuk pelatihan model. Berikut adalah hasil perbedaan sebelum dan sesudah <i>resize</i>: Gambar 3. Hasil Perbedaan sebelum dan sesudah 2. Split Dataset Dataset dibagi menjadi data latih (<i>Training Set</i>) sebesar 80%, Data Uji (<i>Testing Set</i>) sebesar 10%, dan Uji Validasi (<i>Validation Test</i>) sebesar 10%. Pembagian ini menggunakan parameter stratify berdasarkan label kelas untuk memastikan bahwa proporsi ketidakseimbangan data awal tetap sama di kedua subset tersebut sebelum langkah undersampling diterapkan khusus pada data latih.

```

1 total_size = len(dataset)
2 train_size = int(0.8 * total_size)
3 val_size = int(0.10 * total_size)
4 test_size = total_size - train_size - val_size
5
6 train_dataset, val_dataset, test_dataset = random_split(
7     dataset,
8     [train_size, val_size, test_size],
9     generator=torch.Generator().manual_seed(42)
10 )

```

Gambar 4. Potongan code split data

Dari proses split data ini mendapatkan hasil dengan jumlah Train: 3350, Validation: 418, dan Test: 420. Proses split dilakukan secara acak namun deterministik, sehingga setiap kali kode dijalankan ulang, pembagian data akan selalu menghasilkan komposisi yang sama dan eksperimen dapat direproduksi.

3. Undersampling

Undersampling dilakukan untuk mencegah model dari bias terhadap kelas mayoritas selama proses pembelajaran, teknik Random Undersampling diterapkan. Proses penyeimbangan ini sengaja dilakukan hanya pada data latih (Training set) setelah proses split agar tidak terjadi kebocoran data (data leakage) pada data uji. Jumlah sampel pada kelas-kelas mayoritas di potong secara acak sehingga menyamai jumlah sampel kelas minoritas terkecil.

```

1 random.seed(42)
2 balanced_indices = []
3
4 for label, indices in label_indices.items():
5     sampled = random.sample(indices, min_count)
6     balanced_indices.extend(sampled)
7
8 random.shuffle(balanced_indices)
9
10 train_dataset = Subset(dataset, balanced_indices)

```

Gambar 5. Potongan code under sampling


Sebelum undersampling, distribusi kelas pada data latih tidak seimbang dengan *common_rust* (1.044), *healthy* (937), *blight* (911), dan *gray_leaf_spot* (458) sebagai kelas minoritas. Ketidakseimbangan ini berpotensi membuat model bias terhadap kelas mayoritas. Penanganan dilakukan dengan *Random Undersampling*, yaitu menyamakan jumlah seluruh kelas mengikuti kelas minoritas sebanyak 458 sampel per kelas dengan *seed* 42. Hasilnya, total data latih menjadi 1.832 citra dengan distribusi yang seragam, sehingga model dapat mempelajari setiap kelas secara proporsional.

1. CLAHE (*Contrast Limited Adaptive Histogram Equalization*)

CLAHE (*Contrast Limited Adaptive Histogram Equalization*) digunakan untuk meningkatkan kontras citra secara lokal sehingga detail gejala atau bercak penyakit pada daun menjadi lebih jelas dan mudah

Proses rekayasa
fitur

dikenali. Teknik ini meningkatkan kualitas visual citra dengan mempertegas area yang terinfeksi dibandingkan citra asli[6].


A screenshot of a code editor showing two lines of Python code. The first line is `1 clahe= cv2.createCLAHE(clipLimit =2.0, tileGridSize= (8,8))` and the second line is `2 l = clahe.apply(1)`. The code is displayed in a light blue font on a dark background.

```
1 clahe= cv2.createCLAHE(clipLimit =2.0, tileGridSize= (8,8))
2 l = clahe.apply(1)
```

Gambar 6. Potongan code CLAHE

2. *Gaussian Blur*

Setelah kontras citra ditingkatkan menggunakan CLAHE, dilakukan tahap *noise reduction* menggunakan *Gaussian Blur* dengan ukuran kernel 5×5 . Gaussian Blur bekerja dengan melakukan smoothing pada citra sehingga variasi intensitas yang tidak diinginkan dapat dikurangi tanpa menghilangkan struktur utama objek. Tahap ini bertujuan untuk mengurangi gangguan visual pada citra daun jagung seperti serat-serat daun, debu, atau tekstur tanah yang menempel dan menghasilkan citra yang lebih bersih sehingga proses ekstraksi fitur dan klasifikasi oleh model CNN dapat dilakukan dengan lebih optimal[7]. Penggunaan Gaussian filter sebagai teknik preprocessing telah diterapkan pada penelitian deteksi penyakit daun tanaman dan menunjukkan kinerja yang baik dalam mendukung proses klasifikasi citra.

A screenshot of a code editor showing a function definition for applying Gaussian blur. The code is displayed in a light blue font on a dark background.

```
1 def apply_gaussian(img):
2     img = np.array(img)
3     img = cv2.GaussianBlur(img, (5,5), 0)
4     return Image.fromarray(img)
```

Gambar 7. Potongan code Gaussian Blur

3. *To Tensor dan Normalization*

Langkah akhir dari rekayasa fitur adalah mengintegrasikan seluruh tahapan pra-pemrosesan ke dalam sebuah pipeline transformasi data. Tahapan ini bertujuan menghasilkan data masukan yang lebih konsisten dan berkualitas sehingga dapat meningkatkan performa model deep learning. Selain itu, normalisasi citra merupakan salah satu teknik *preprocessing* yang berkontribusi terhadap peningkatan akurasi klasifikasi pada model berbasis CNN[8]. Citra dikonversi menjadi bentuk matriks tensor *Pytorch* yang memiliki rentang nilai piksel (0, 1). Selanjutnya, dilakukan proses normalisasi nilai piksel menggunakan nilai rata-rata dan standar deviasi dari dataset *ImageNet*.


```

1  transform = transforms.Compose([
2      transforms.Lambda(apply_clahe),
3      transforms.Lambda(apply_gaussian),
4      transforms.ToTensor(),
5      transforms.Normalize(
6          mean=[0.485, 0.456, 0.406],
7          std=[0.229, 0.224, 0.225]
8      )
9  ])
10
11 dataset.transform = transform

```

Gambar 8. Potongan kode *To Tensor* dan *Normalization*

Berdasarkan serangkaian tahapan *preprocessing* yang telah dijabarkan, mulai dari perbaikan kontras lokal dengan CLAHE, reduksi *noise* menggunakan *Gaussian Blur*, hingga standardisasi nilai piksel melalui *Normalization* diperoleh perubahan visual pada citra secara bertahap. Perbandingan hasil dari masing-masing proses rekayasa fitur pada citra daun jagung tersebut ditunjukkan pada Gambar 10.




Gambar 9. Hasil *Image Preprocessing*


Hasil Visualisasi pada Gambar 9, menunjukkan perubahan karakteristik citra daun jagung yang signifikan pada setiap tahapannya. Pada citra hasil CLAHE, kontras warna meningkat sehingga garis serat daun dan area bercak gejala penyakit tampak lebih tegas dan tajam, hal ini akan memudahkan pemisahan visual anata jaringan sehat dan terinfeksi. Kemudian, penerapan *Gaussian Blur* memberikan efek halus yang secara efektif mereduksi *noise* minor seperti tekstur tanah atau detail latar belakang yang tidak relevan tanpa mengaburkan batas wilayah bercak penyakit utama. Terakhir, pada tahap *Normalization*, meskipun secara kasat mata perubahannya tidak terlalu kontras, proses ini berhasil menyamakan rentang skala intensitas piksel dan distribusi warna sehingga seluruh dataset menjadi seragam dan berada dalam kondisi optimal sebelum masuk ke dalam proses ekstraksi fitur oleh arsitektur MobileNetV2.

4. *Features Extraction*

Tahapan rekayasa fitur dilanjutkan dengan proses ekstraksi fitur berbasis *Deep Learning*. Citra hasil *preprocessing* kemudian dimasukkan

	ke model <i>Convolutional Neural Network</i> (CNN) dengan arsitektur <i>MobileNetV2</i>. Pada tahap ini model mengekstraksi berbagai fitur visual penting seperti tekstur, pola bercak, bentuk kerusakan daun, dan variasi warna yang berkaitan dengan penyakit tanaman jagung[9].  <pre> 1 DEVICE = torch.device("cuda" if torch.cuda.is_available() else "cpu") 2 3 mobilenet = models.mobilenet_v2(weights=models.MobileNet_V2_Weights.DEFAULT) 4 5 feature_extractor = mobilenet.features 6 7 feature_extractor = feature_extractor.to(DEVICE) 8 9 for param in feature_extractor.parameters(): 10 param.requires_grad = False 11 12 feature_extractor.eval() </pre> Gambar 10. Potongan kode <i>Feature Extraction</i>
Temuan	Terdapat beberapa temuan khusus setelah proses pelatihan yang dilakukan yang memengaruhi performa model, antara lain: 1. Penerapan <i>Under Sampling</i> Setelah <i>Data Splitting</i> Dataset awal memiliki tingkat ketidakseimbangan (<i>imbalance</i>) kelas yang tinggi. Temuan penting dalam penanganannya adalah proses <i>under sampling</i> diterapkan setelah data di <i>splitting</i> menjadi data <i>train</i>, <i>validation</i>, dan <i>test</i>. Hal ini dilakukan untuk menghindari <i>data leakage</i> (kebocoran informasi), sehingga data validasi dan data uji tetap objektif. 2. Penambahan <i>Image Preprocessing</i> Ditemukan bahwa citra asli daun jagung memiliki variasi pencahayaan dan <i>noise</i> yang dapat mengaburkan fitur penyakit. Penambahan metode CLAHE terbukti efektif meningkatkan kontras visual pada tepi bercak, sementara <i>Gaussian Blur</i> berhasil mereduksi derau serat daun. Kombinasi ini membantu lapisan konvolusi CNN dalam mengekstrak fitur pola, tekstur, dan warna penyakit secara lebih optimal. 3. Indikasi Adanya <i>Overfitting</i> Selama proses pelatihan awal, model sempat menunjukkan gejala <i>overfitting</i> ringan dimana akurasi data latih meningkat pesat namun melambat pada data validasi. Temuan ini yang mendasari diperlukannya tahapan <i>hyperparameter tuning</i> pada revisi progress selanjutnya guna mendapatkan hasil akurasi akhir yang paling stabil dan optimal. 4. Penemuan Inkonsistensi Hasil Akurasi Sempat ditemukan inkonsistensi berupa hasil akurasi yang berubah-ubah pada setiap kali tombol <i>run</i> dieksekusi, meskipun tidak ada perubahan kode. Fenomena ini diidentifikasi sebagai sifat acak bawaan (<i>stochastic</i>) <i>PyTorch</i> pada CPU (inisialisasi bobot awal dan pengocokan <i>DataLoader</i>), yang kemudian telah berhasil diselesaikan dengan mengunci seluruh <i>seed</i> keacakan global pada angka 42. 5. Perubahan susunan BGR pada CLAHE Pada code fungsi awal CLAHE, untuk mengubah gambar kedalam format LAB digunakannya <code>cv2.COLOR_BGR2LAB</code>. Akan tetapi pada tahapan revisi diubah menjadi <code>cv2.COLOR_RGB2LAB</code>. Meskipun secara kasatmata hanya mengubah susunan penulisan <i>blue</i>, dan <i>red</i>, akan tetapi terdapat perubahan akurasi yang dimiliki salah satu model yang telah

	dibangun, yaitu pada model <i>random forest</i>. Akibat yang terjadi pada model tersebut penurunan akurasi sebesar 0,01 (1%), meskipun terlihat kecil hal ini dapat berdampak pada perbandingan model model nantinya. 6. Penyeragaman kanal Terdapat 4 citra yang terdeteksi sebagai citra dengan 4 saluran, yaitu RGBA. Agar mempermudah dalam proses <i>resize</i> dan seterusnya, maka dilakukan normalisasi perubahan empat saluran menjadi 3 saluran. Hal ini kami lakukan agar tidak terjadi <i>error</i> pada saat melakukan tahapan <i>resize</i>, CLAHE, dan lain sebagainya. Secara keseluruhan, temuan-temuan khusus ini menunjukkan bahwa keberhasilan klasifikasi penyakit daun jagung tidak hanya bergantung pada kecanggihan arsitektur model CNN yang digunakan, melainkan juga pada kualitas <i>preprocessing</i> citra, keaslian penanganan distribusi data, serta konsistensi lingkungan komputasi.																																																																																																																												
Hasil dan Pembahasan																																																																																																																													
Hasil eksplorasi data	Sebelum melakukan <i>preprocessing</i> dilakukannya data eksplorasi agar dapat memahami bagaimana karakteristik data yang dimiliki. Hal ini bertujuan untuk mengidentifikasi kualitas data, distribusi kelas, tingkat <i>sparsity</i>, keberadaan <i>outlier</i>, <i>missing value</i>, dan duplikat yang dapat mempengaruhi bagaimana kinerja model nantinya. Hasil visualisasi data disajikan melalui beberapa visualisasi sebagai berikut: 1. Tingkat <i>sparsity</i>. Agar dapat mengetahui bagaimana nilai data yang tidak tersedia pada citra, maka dilakukan cek tingkat <i>sparsity</i> data agar mengetahui hal tersebut. <table border="1"> <caption>Data for Gambar 11. Distribusi Sparsity</caption> <thead> <tr> <th>Sparsity Level</th> <th>Count</th> </tr> </thead> <tbody> <tr><td>0</td><td>340</td></tr> <tr><td>1</td><td>5</td></tr> <tr><td>2</td><td>5</td></tr> <tr><td>3</td><td>5</td></tr> <tr><td>4</td><td>5</td></tr> <tr><td>5</td><td>5</td></tr> <tr><td>6</td><td>5</td></tr> <tr><td>7</td><td>5</td></tr> <tr><td>8</td><td>5</td></tr> <tr><td>9</td><td>5</td></tr> <tr><td>10</td><td>5</td></tr> <tr><td>11</td><td>5</td></tr> <tr><td>12</td><td>5</td></tr> <tr><td>13</td><td>5</td></tr> <tr><td>14</td><td>5</td></tr> <tr><td>15</td><td>5</td></tr> <tr><td>16</td><td>5</td></tr> <tr><td>17</td><td>5</td></tr> <tr><td>18</td><td>5</td></tr> <tr><td>19</td><td>5</td></tr> <tr><td>20</td><td>5</td></tr> <tr><td>21</td><td>5</td></tr> <tr><td>22</td><td>5</td></tr> <tr><td>23</td><td>5</td></tr> <tr><td>24</td><td>5</td></tr> <tr><td>25</td><td>5</td></tr> <tr><td>26</td><td>5</td></tr> <tr><td>27</td><td>5</td></tr> <tr><td>28</td><td>5</td></tr> <tr><td>29</td><td>5</td></tr> <tr><td>30</td><td>5</td></tr> <tr><td>31</td><td>5</td></tr> <tr><td>32</td><td>5</td></tr> <tr><td>33</td><td>5</td></tr> <tr><td>34</td><td>5</td></tr> <tr><td>35</td><td>5</td></tr> <tr><td>36</td><td>5</td></tr> <tr><td>37</td><td>5</td></tr> <tr><td>38</td><td>5</td></tr> <tr><td>39</td><td>5</td></tr> <tr><td>40</td><td>5</td></tr> <tr><td>41</td><td>5</td></tr> <tr><td>42</td><td>5</td></tr> <tr><td>43</td><td>5</td></tr> <tr><td>44</td><td>5</td></tr> <tr><td>45</td><td>5</td></tr> <tr><td>46</td><td>5</td></tr> <tr><td>47</td><td>5</td></tr> <tr><td>48</td><td>5</td></tr> <tr><td>49</td><td>5</td></tr> <tr><td>50</td><td>5</td></tr> <tr><td>51</td><td>5</td></tr> <tr><td>52</td><td>5</td></tr> <tr><td>53</td><td>5</td></tr> <tr><td>54</td><td>5</td></tr> <tr><td>55</td><td>5</td></tr> <tr><td>56</td><td>5</td></tr> <tr><td>57</td><td>5</td></tr> <tr><td>58</td><td>5</td></tr> <tr><td>59</td><td>5</td></tr> <tr><td>60</td><td>5</td></tr> </tbody> </table> Gambar 11. Distribusi <i>Sparsity</i>. Berdasarkan gambar 11, diketahui bahwa mayoritas citra yang digunakan memiliki tingkat keterbatasan data yang kecil sehingga dapat dinyatakan bahwa dataset yang digunakan memiliki citra yang mengandung banyak informasi. Berdasarkan rata-rata <i>sparsity</i> yaitu 4,664% nilai menunjukkan dataset dapat dikategorikan cukup padat (<i>dense</i>), sehingga informasi visual yang tersedia masih memadai untuk pelatihan model. 2. Distribusi kelas. Pengecekan distribusi kelas dilakukan agar dapat mengetahui apakah dataset yang dimiliki tidak seimbang atau seimbang. Berikut merupakan hasil visualisasinya:	Sparsity Level	Count	0	340	1	5	2	5	3	5	4	5	5	5	6	5	7	5	8	5	9	5	10	5	11	5	12	5	13	5	14	5	15	5	16	5	17	5	18	5	19	5	20	5	21	5	22	5	23	5	24	5	25	5	26	5	27	5	28	5	29	5	30	5	31	5	32	5	33	5	34	5	35	5	36	5	37	5	38	5	39	5	40	5	41	5	42	5	43	5	44	5	45	5	46	5	47	5	48	5	49	5	50	5	51	5	52	5	53	5	54	5	55	5	56	5	57	5	58	5	59	5	60	5
Sparsity Level	Count																																																																																																																												
0	340																																																																																																																												
1	5																																																																																																																												
2	5																																																																																																																												
3	5																																																																																																																												
4	5																																																																																																																												
5	5																																																																																																																												
6	5																																																																																																																												
7	5																																																																																																																												
8	5																																																																																																																												
9	5																																																																																																																												
10	5																																																																																																																												
11	5																																																																																																																												
12	5																																																																																																																												
13	5																																																																																																																												
14	5																																																																																																																												
15	5																																																																																																																												
16	5																																																																																																																												
17	5																																																																																																																												
18	5																																																																																																																												
19	5																																																																																																																												
20	5																																																																																																																												
21	5																																																																																																																												
22	5																																																																																																																												
23	5																																																																																																																												
24	5																																																																																																																												
25	5																																																																																																																												
26	5																																																																																																																												
27	5																																																																																																																												
28	5																																																																																																																												
29	5																																																																																																																												
30	5																																																																																																																												
31	5																																																																																																																												
32	5																																																																																																																												
33	5																																																																																																																												
34	5																																																																																																																												
35	5																																																																																																																												
36	5																																																																																																																												
37	5																																																																																																																												
38	5																																																																																																																												
39	5																																																																																																																												
40	5																																																																																																																												
41	5																																																																																																																												
42	5																																																																																																																												
43	5																																																																																																																												
44	5																																																																																																																												
45	5																																																																																																																												
46	5																																																																																																																												
47	5																																																																																																																												
48	5																																																																																																																												
49	5																																																																																																																												
50	5																																																																																																																												
51	5																																																																																																																												
52	5																																																																																																																												
53	5																																																																																																																												
54	5																																																																																																																												
55	5																																																																																																																												
56	5																																																																																																																												
57	5																																																																																																																												
58	5																																																																																																																												
59	5																																																																																																																												
60	5																																																																																																																												




Gambar 12. Distribusi Kelas

Distribusi kelas berdasarkan gambar 12 menunjukkan bahwa adanya kondisi ketidak seimbangan data. Rasio yang diperoleh untuk masing-masing kelas adalah 2,02:1,00:2,28:2,00. Hal ini menunjukkan bahwa pada kelas *gray_leaf_spot* hanya memiliki data sebanyak 574 citra, sedangkan pada kelas *blight*, *health*, dan *common_rush* memiliki jumlah data citra dua kali lipat dari kelas *gray_leaf_spot*.

3. *Outlier*.

Berikut merupakan outlier yang dimiliki dataset kami.



Gambar 13. Deteksi Outlier

Gambar 13 menunjukkan terdapat nilai ekstrim pada beberapa atribut dataset, yaitu *width* sebanyak 335 data, *height* sebanyak 336 data, dan *file size* sebanyak 332 data. Keberadaan outlier ini mengidentifikasi adanya variasi ukuran dimensi citra dan ukuran file yang cukup beragam dibandingkan mayoritas data.

4. Duplikasi dataset

Pada dataset ini terdapat duplikasi hanya dua data saja. Berikut merupakan citra dari data yang terduplikasi :



Gambar 14. Duplikat Nama

Berdasarkan gambar 14, ternyata duplikasi yang terdeteksi berada pada kelas *blight*. Duplikasi hanya berupa nama file, akan tetapi isi citranya dan jenis filenya


	berbeda. Hal ini, tidak kami perbaiki karena duplikasi bukan berupa citra yang terduplikasi. Akan tetapi hanya sebatas nama dan jenis filenya 5. Jenis <i>Channels</i> Berdasarkan gambar x yang tertera pada duplikasi, diketahui bahwa ternyata dataset kami memiliki citra yang jenis kanalnya RGBA, yaitu dengan tipe filenya jpeg. Setelah dilakukannya pengecekan, diketahui bahwa terdapat hanya 4 citra yang memiliki jenis kanal tersebut. Keempat citra tersebut kami standarisasi mengikuti kanal mayoritas yaitu RGB agar mempermudah dalam proses <i>preprocessing</i> nantinya.
Hasil eksperimen	Setelah melalui tahapan <i>preprocessing</i>, proses selanjutnya adalah pelatihan model klasifikasi. Pada penelitian ini digunakannya CNN sebagai <i>feature extractor</i> agar nantinya saat pemodelan dapat lebih mudah memahami bagaimana karakteristik yang terkandung pada citra seperti tekstur, pola bercak, bentuk kerusakan daun, dan variasi warna yang berkaitan dengan penyakit tanaman jagung. Gambar 15. Visualisasi fitur maps Berdasarkan Gambar 15, proses ekstraksi fitur pada citra daun jagung dilakukan secara bertahap melalui layer konvolusi yang semakin mendalam. Pada lapisan awal (<i>Conv 1</i> dan <i>Conv 2</i>), model membaca gambar input berukuran $224 \times 224 \times 3$ piksel untuk mengekstrak fitur sederhana seperti garis tepi bercak, warna dasar daun, dan sudut-sudut bercak penyakit. Seiring masuknya gambar ke lapisan yang lebih dalam (<i>Conv 3</i> hingga <i>Conv 5</i>), ukuran spasial citra diperkecil lewat proses <i>Pooling</i> sementara jumlah filternya ditingkatkan. Hasil akhirnya berupa kumpulan matriks fitur (<i>feature maps</i>) yang menangkap karakteristik unik dari masing-masing penyakit daun jagung sebanyak 1280 fitur, hasil tersebut kemudian siap ke tahap klasifikasi akhir. Setelah melalui tahapan <i>feature extractor</i>, tahapan selanjutnya adalah <i>ensemble classifier</i> menggunakan dua model perbandingan, yaitu random forest dan <i>XGBoost</i>. 1. <i>Random Forest</i> Model random forest di bangun menggunakan algoritma <i>RandomForestClassifier</i>. Ditentukannya parameter pohon keputusannya 200 agar kemampuan model dalam melakukan klasifikasi nantinya menjadi lebih stabil dan akurat karena hasil prediksi melalui mekanisme <i>voting</i> dari seluruh pohon yang terbentuk. Berikut merupakan hasil klasifikasi menggunakan model <i>random forest</i>:

Tabel 1. *Matrix Evaluation Random Forest Classification*

	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>
<i>Blight</i>	0,89	0,87	0,88	123
<i>Common Rust</i>	1,00	0,91	0,95	129
<i>Gray Leaf Spot</i>	0,76	0,96	0,85	55
<i>Health</i>	1,00	1,00	1,00	113
<i>Accuracy</i>			0,93	420
<i>Macro Average</i>	0,91	0,94	0,92	420
<i>Weighted Average</i>	0,94	0,93	0,93	420

Berdasarkan tabel x, model *random forest* memiliki nilai akurasi sebesar 93% pada data *test*, menunjukkan bahwa model dapat mengklasifikasikan sebagian besar citra daun ke dalam kelas penyakit yang sesuai. Selain itu, nilai *macro average F1-Score* sebesar 92%, dan *Weighted Average F1-Score* sebesar 93% . Hal ini menunjukkan bahwa performa model tergolong baik dan seimbang pada seluruh kelasnya.

Hasil akurasi data *train* menggunakan model sebesar 0,9995, jika dibandingkan dengan nilai data *test* sebesar 0,9285 dapat diketahui bahwa terjadi sedikit *overfitting* pada model, akan tetapi model masih mampu mempertahankan tingkat akurasi saat di uji dengan data yang belum pernah dilihat sebelumnya.

Gambar 16. *Top 20 Feature Importance Random Forest*

Berdasarkan gambar 16, diketahui bahwa fitur hasil ekstraksi *MobileNetV2* yang memiliki pengaruh paling besar adalah F249, dan F862 dengan nilai sekitar 0,021 dan 0,23, kemudian disusul oleh Fitur F1254, F92, F928, dan seterusnya. Nilai importance yang lebih tinggi menunjukkan bahwa fitur tersebut lebih sering digunakan oleh pohon-pohon keputusan *Random Forest* dalam membedakan kelas penyakit daun jagung sehingga memberikan kontribusi yang lebih besar.

2. *XGBoost*

Model *XGBoost* bekerja dengan membangun model secara bertahap untuk memperbaiki kesalahan prediksi sebelumnya, sehingga mampu menghasilkan akurasi klasifikasi yang lebih baik dan efisien yada hasil ekstrak fitur sebelumnya. Model *XGBoost* di bangun dengan nilai *n_estimators* sebesar 150, yang artinya pohon


keputusan(*gradient-boosted trees*) yang akan di bangun, *max_depth* sebesar 5, yang artinya kedalaman maksimal setiap pohon yang dibangun.

Tabel 2. *Matrix Evaluation XGBoost Classification*

	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>
<i>Blight</i>	0,90	0,90	0,90	123
<i>Common Rust</i>	1,00	0,94	0,97	129
<i>Gray Leaf Spot</i>	0,79	0,91	0,85	55
<i>Health</i>	0,99	0,98	0,99	113
<i>Accuracy</i>			0,94	420
<i>Macro Average</i>	0,92	0,93	0,93	420
<i>Weighted Average</i>	0,94	0,94	0,94	420

Berdasarkan tabel 2, model *XGBoost* yang telah di bangun memperoleh nilai akurasi sebesar 94% , hasil tersebut menunjukkan bahwa model sangat baik dalam mengklasifikasikan citra ke kelas penyakit daun jagung yang sesuai. Nilai *macro average F1-Score* menunjukkan nilai sebesar 0,93 dan nilai *weighted average F1-Score* sebesar 0,94 yang menunjukkan bahwa performa model dalam melakukan klasifikasi sangat baik dan seimbang pada seluruh kelasnya.

Akurasi model *XGBoost* pada data *train* menghasilkan nilai sebesar 0,9994. Jika dibandingkan dengan nilai akurasi pada data uji yaitu 0,9357, terjadi sedikit *overfitting* akan tetapi model masih mampu memprediksi penyakit daun jagung, dan dapat mempertahankan tingkat akurasi saat di uji dengan data yang belum pernah dilihat yang sebelumnya.



Gambar 17. *Top 20 Feature Importance XGBoost*

Berdasarkan gambar 17, fitur ekstraksi yang sering digunakan sebagai keputusan merupakan fitur F1254 dengan nilai berada pada kisaran 0,046. Kemudian disusul oleh fitur ekstraksi F862 dengan nilai berada pada kisaran 0,038, dan yang ketiga Fitur ekstraksi F243 berada pada nilai 0,023, dan yang lainnya. Nilai importance yang lebih tinggi menunjukkan bahwa fitur tersebut lebih sering digunakan oleh pohon-pohon keputusan *XGBoost* dalam membedakan kelas penyakit daun jagung sehingga memberikan kontribusi yang lebih besar.

	Berdasarkan hasil kedua model yang telah dibangun dan dilatih, dapat diketahui bahwa ternyata model terbaik berdasarkan nilai akurasi yang dimiliki <i>XGBoost</i> sedikit lebih unggul dibandingkan <i>Random Forest</i>. <i>XGBoost</i> memiliki nilai akurasi sebesar 0,9357 sedangkan <i>Random Forest</i> memiliki nilai akurasi sebesar 0,9285. Perbedaan yang dimiliki tidak signifikan tetapi berdasarkan <i>F1-Score</i> masing-masing kelas <i>XGBoost</i> memiliki nilai yang lebih merata, seperti pada kelas <i>blight</i> sebesar 90%, <i>common_rust</i> sebesar 97%, <i>gray_leaf_spot</i> 0,85%, dan <i>healthy</i> dengan nilai 0,99%. Meskipun perbedaan akurasi tidak terlalu jauh masih dapat disimpulkan bahwa <i>XGBoost</i> tetap menjadi model terbaik.
Kesimpulan dan Saran	
Kesimpulan	Berdasarkan hasil penelitian yang telah dilakukan, model <i>random forest</i> dan <i>XGBoost</i> mampu melakukan klasifikasi penyakit daun jagung dengan performa yang baik. <i>XGBoost</i> memiliki performa yang lebih tinggi sehingga disimpulkan sebagai model terbaik pada penelitian ini. Hasil penelitian ini diharapkan dapat berkontribusi dalam menyelesaikan permasalahan identifikasi penyakit daun jagung yang sering kali masih dilakukan manual dan memerlukan keahlian khusus untuk membedakan jenis penyakit berdasarkan gejala visual pada daun . melalui penerapan CNN sebagai metode ekstraksi fitur dan algoritma <i>ensemble classifier</i> berupa <i>random forest</i> dan <i>XGBoost</i> sebagai metode klasifikasi, sistem mampu melakukan identifikasi penyakit daun jagung secara otomatis dengan tingkat akurasi yang sangat tinggi. Temuan utama dari penelitian ini adalah kombinasi CNN sebagai <i>feature extractor</i> dan <i>XGBoost</i> sebagai <i>classifier</i> mampu menghasilkan performa klasifikasi yang sangat baik dalam mendeteksi penyakit daun jagung. Temuan ini dapat dimanfaatkan oleh masyarakat, khususnya petani, penyuluh pertanian, penelitian, dan instansi di sektor pertanian, sebagai dasar pengembangan sistem deteksi penyakit tanaman secara otomatis. Dalam jangka panjang, hasil penelitian ini juga dapat mendukung pengembangan teknologi <i>smart farming</i> dan transformasi digital sektor pertanian, sehingga dapat berkontribusi terhadap peningkatan efisiensi budidaya tanaman serta mendukung ketahanan pangan yang berkelanjutan.
Saran	Terdapat beberapa kendala yang dihadapi selama proses eksperimen, beberapa saran dapat direkomendasikan untuk penelitian selanjutnya. Pertama, terkait kendala inkonsistensi hasil akurasi model yang masih berubah-ubah akibat sifat stokastik pada <i>data loader</i> dan proses <i>shuffling</i> data meskipun <i>seed</i> global telah dikunci, peneliti berikutnya disarankan untuk menerapkan kontrol keacakan yang lebih ketat pada tingkat pekerja (<i>worker-specific seeding</i>) dan memastikan reproduksibilitas penuh pada lingkungan GPU/CPU yang digunakan. Kedua, penelitian selanjutnya perlu menerapkan teknik augmentasi data (<i>Data Augmentation</i>) untuk mengatasi masalah ketidakseimbangan kelas tanpa harus melakukan <i>undersampling</i> ekstrem yang membuang banyak informasi penting pada kelas mayoritas.

	Selain itu, adanya indikasi <i>overfitting</i> ringan dimana akurasi data latih jauh melampaui data uji, penggunaan <i>hyperparameter tuning</i> seperti <i>Grid Search</i> sangat direkomendasikan untuk mencari kombinasi parameter model yang lebih stabil. Terakhir, dari sisi implementasi praktis, model terbaik dapat diintegrasikan ke dalam aplikasi perangkat bergerak (<i>mobile application</i>) serta dikembangkan lebih lanjut agar mampu mendeteksi tingkat keparahan penyakit (<i>severity level</i>) daun jagung secara <i>real-time</i> di lapangan.
Daftar Pustaka	
Daftar Pustaka	[1] S. Pan <i>dkk.</i>, “Intelligent diagnosis of northern corn leaf blight with deep learning model,” <i>J. Integr. Agric.</i>, vol. 21, no. 4, hlm. 1094–1105, Apr 2022, doi: 10.1016/S2095-3119(21)63707-3. [2] C. Ashwini dan V. Sellam, “An optimal model for identification and classification of corn leaf disease using hybrid 3D-CNN and LSTM,” <i>Biomed. Signal Process. Control</i>, vol. 92, hlm. 106089, Jun 2024, doi: 10.1016/j.bspc.2024.106089. [3] A. Samit Hatem, M. S. Altememe, dan M. A. Fadhel, “Identifying corn leaves diseases by extensive use of transfer learning: a comparative study,” <i>Indones. J. Electr. Eng. Comput. Sci.</i>, vol. 29, no. 2, hlm. 1030, Feb 2023, doi: 10.11591/ijeecs.v29.i2.pp1030-1038. [4] F. S. Ishengoma dan N. N. Lyimo, “Ensemble model for grape leaf disease detection using CNN feature extractors and random forest classifier,” <i>Heliyon</i>, vol. 10, no. 12, hlm. e33377, Jun 2024, doi: 10.1016/j.heliyon.2024.e33377. [5] A. M. P. dan P. Reddy, “Ensemble of CNN models for classification of groundnut plant leaf disease detection,” <i>Smart Agric. Technol.</i>, vol. 6, hlm. 100362, Des 2023, doi: 10.1016/j.atech.2023.100362. [6] V. T. Sai, N. E. Sai Akhil, T. J. M. Jashnavi, dan N. V. K. Kanakala, “Image Quality Enhancement for Wheat rust Diseased Leaf Image using Histogram Equalization & CLAHE,” <i>E3S Web Conf.</i>, vol. 391, hlm. 01029, 2023, doi: 10.1051/e3sconf/202339101029. [7] Md. I. Hossain, S. Jahan, Md. R. Al Asif, Md. Samsuddoha, dan K. Ahmed, “Detecting tomato leaf diseases by image processing through deep convolutional neural networks,” <i>Smart Agric. Technol.</i>, vol. 5, hlm. 100301, Okt 2023, doi: 10.1016/j.atech.2023.100301. [8] M. J. Yousif, “Enhancing The Accuracy of Image Classification Using Deep Learning and Preprocessing Methods,” <i>Artif. Intell. Robot. Dev. J.</i>, Jan 2024, doi: 10.52098/airdj.2023348. [9] F. Khan, N. Zafar, M. N. Tahir, M. Aqib, H. Waheed, dan Z. Haroon, “A mobile-based system for maize plant leaf disease detection and classification using deep learning,” <i>Front. Plant Sci.</i>, vol. 14, hlm. 1079366, Mei 2023, doi: 10.3389/fpls.2023.1079366.